

UNIwersYTET RZESZOWSKI
WYDZIAŁ NAUK ŚCISŁYCH I TECHNICZNYCH
INSTYTUT INFORMATYKI



Kacper Bułaś, Mateusz Bocak
127754, 125104

Informatyka

*Klasyfikacja gestów języka migowego ASL przy użyciu Sign
Language MNIST*

Grupa: 1

Prowadzący
dr Zbigniew Gomółka

Rzeszów 2025

Spis treści

1. Cel projektu i wprowadzenie teoretyczne.....	7
1.1. Cel projektu	7
1.2. Wprowadzenie teoretyczne.....	7
1.2.1. Zbiór danych Sign Language MNIST.....	7
1.2.2. Metody klasyfikacji.....	8
1.2.3. Detekcja dłoni — MediaPipe.....	8
1.2.4. Normalizacja cech.....	8
2. Opis zastosowanej metody i implementacji.....	9
2.1. Opis zastosowanej metody	9
2.1.1. Ogólny schemat systemu	9
2.1.2. Potok przetwarzania danych	10
2.1.3. Warunki pomiarowe przy inferowaniu z kamery	10
2.2. Opis implementacji.....	11
2.2.1. Struktura projektu	11
2.2.2. Interfejs wiersza poleceń.....	11
2.2.3. Implementacja klasyfikatorów	12
2.2.4. Serializacja modeli.....	13
2.2.5. Główne zależności	13
3. Eksperymenty i wyniki.....	14
3.1. Opis eksperymentów	14
3.1.1. Cel eksperymentów.....	14
3.1.2. Podział danych	14
3.1.3. Procedura trenowania i ewaluacji	14
3.1.4. Test w warunkach rzeczywistych.....	15
3.2. Wyniki	15
3.2.1. Dokładność na zbiorze testowym	15
3.2.2. Obserwacje jakościowe z inferencji kamerowej	15
3.3. Dyskusja wyników	16
3.3.1. Przewaga CNN nad metodami klasycznymi.....	16
3.3.2. Równoważność SVC i Lasu Losowego	16
3.3.3. Ograniczenia podejścia pikselowego	16
3.3.4. Rola MediaPipe w systemie.....	16
3.3.5. Kierunki ulepszeń	16
4. Wnioski i dodatek	17
4.1. Wnioski.....	17
Dodatek: Instrukcja samodzielnej realizacji ćwiczenia	17

5. Implementacja systemu	20
5.1. Architektura logiczna	20
5.2. Przetwarzanie danych	20
5.3. Uczenie modeli	20
5.4. Ewaluacja jakości	20
5.5. Inferencja: CSV i kamera	21
5.6. Interfejs CLI	21
6. Wyniki i analiza	22
6.1. Założenia środowiska testowego	22
6.2. Wyniki porównawcze modeli	22
6.3. Schemat przepływu systemu	22
6.4. Analiza jakości inferencji w czasie rzeczywistym	23
6.5. Ograniczenia obecnej wersji	23
7. Wnioski	24
7.1. Podsumowanie realizacji	24
7.2. Ocena zastosowanych metod	24
7.3. Ograniczenia i ryzyka	24
7.4. Kierunki dalszego rozwoju	24
7.5. Wniosek końcowy	24
Bibliografia	25
Spis rysunków	26
Spis tabel	27
Spis listingów	28

1. Cel projektu i wprowadzenie teoretyczne

1.1. Cel projektu

Celem ćwiczenia jest zaprojektowanie i zaimplementowanie systemu klasyfikacji statycznych gestów dłoni odpowiadających literom amerykańskiego języka migowego (ASL — *American Sign Language*). System o nazwie **mnist-translator** pracuje w czasie rzeczywistym, korzystając z obrazu z kamery internetowej, i jest w stanie rozpoznać 24 litery alfabetu ASL (A–Y, z wyłączeniem liter J i Z, które wymagają ruchu dłoni).

Szczegółowe cele ćwiczenia laboratoryjnego obejmują:

- zapoznanie się ze zbiorem danych Sign Language MNIST — jego strukturą, liczebnością klas i formatem próbek,
- opanowanie potoku przetwarzania obrazu: od przechwycenia klatki wideo przez detekcję dłoni za pomocą biblioteki MediaPipe, aż po ekstrakcję wektora cech dla klasyfikatora,
- wytrenowanie i porównanie trzech modeli uczenia maszynowego: **SVC z jądrem RBF**, **Lasu Losowego** oraz **konwolucyjnej sieci neuronowej (CNN)**,
- opracowanie modułowej aplikacji konsolowej umożliwiającej trenowanie, ewaluację i uruchamianie wnioskowania zarówno offline (z pliku CSV), jak i na żywo (z kamery),
- sformułowanie wniosków o możliwościach zastosowania klasyfikatorów pikselowych do rozpoznawania gestów w warunkach rzeczywistych.

1.2. Wprowadzenie teoretyczne

1.2.1. Zbiór danych Sign Language MNIST

Sign Language MNIST jest adaptacją oryginalnego zbioru MNIST cyfr [5] do zadania rozpoznawania liter języka migowego. Każda próbka to obraz dłoni o rozmiarze 28×28 pikseli w skali szarości, spłaszczony do wektora 784 cech liczbowych (wartości pikseli 0–255).

Tabela 1.1. Statystyki zbioru danych Sign Language MNIST

Podzbiór	Liczba próbek	Liczba klas
Treningowy	27 455	24
Testowy	7 172	24

Litery J (indeks 9) i Z (indeks 25) zostały wyłączone ze zbioru, ponieważ ich znaki ASL wymagają ruchu i nie mogą być reprezentowane przez pojedynczy obraz statyczny. Mapowanie etykiet na litery opisuje wzór:

$$\text{litera} = \text{chr}(\text{ord}('A') + \text{label}), \quad \text{label} \in \{0, 1, \dots, 8, 10, \dots, 24\}.$$

1.2.2. Metody klasyfikacji

1.2.2.1. Maszyna wektorów nośnych (SVM/SVC)

Maszyna wektorów nośnych [2] szuka hiperpłaszczyzny maksymalnie rozdzielającej klasy w przestrzeni cech. W przypadku nieliniowych granic decyzji stosowane są jądra (*kernels*), które implicitnie mapują dane do przestrzeni wyższego wymiaru. Jądro RBF (*Radial Basis Function*) definiowane jest jako:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad (1.1)$$

gdzie $\gamma > 0$ jest parametrem szerokości jądra. Dla danych w przestrzeni 784-wymiarowej SVC z jądrem RBF jest w stanie uchwycić złożone relacje między pikselami bez jawnej inżynierii cech.

1.2.2.2. Las Losowy (*Random Forest*)

Las Losowy [1] jest metodą łączącą (*ensemble*) drzewa decyzyjne. Każde drzewo trenowane jest na losowej próbie danych (*bootstrap*) i korzysta z losowego podzioru cech przy każdym podziale. Klasyfikacja odbywa się przez głosowanie większościowe:

$$\hat{y} = \arg \max_c \sum_{t=1}^T \mathbf{1}[h_t(\mathbf{x}) = c], \quad (1.2)$$

gdzie T to liczba drzew, a h_t to t -te drzewo decyzyjne. Las Losowy jest odporny na przeuczenie i nie wymaga normalizacji danych wejściowych.

1.2.2.3. Konwolucyjna sieć neuronowa (CNN)

Konwolucyjne sieci neuronowe [4] są szczególnie efektywne dla danych obrazowych, ponieważ uczą przestrzennych filtrów bezpośrednio z pikseli. Architektura zastosowana w projekcie składa się z dwóch bloków konwolucyjnych ($\text{Conv2D} \rightarrow \text{MaxPool2D}$), warstwy spłaszczającej (Flatten) i gęstej warstwy wyjściowej z funkcją *softmax*.

CNN operuje na siatce pikseli 28×28 , co pozwala jej wychwytywać lokalne wzorce (krawędzie, narożniki, faktury) niedostępne dla klasyfikatorów operujących na spłaszczonym wektorze cech.

1.2.3. Detekcja dłoni — MediaPipe

MediaPipe [6] jest platformą Google do uczenia maszynowego na urządzeniach końcowych. Moduł *Gesture Recognizer* wykrywa dłoń w klatce wideo i zwraca 21 punktów kluczowych (*landmarks*) w przestrzeni 3D. Na ich podstawie wyznaczany jest prostokąt otaczający (*bounding box*), który jest przycinany i przeskalowywany do formatu 28×28 pikseli.

1.2.4. Normalizacja cech

Wartości pikseli z zakresu $[0, 255]$ są normalizowane do przedziału $[0, 1]$ przez proste dzielenie:

$$x' = \frac{x}{255,0}.$$


Zapewnia to zgodność formatu z danymi treningowymi ze zbioru Sign Language MNIST.

2. Opis zastosowanej metody i implementacji

2.1. Opis zastosowanej metody

2.1.1. Ogólny schemat systemu

System **mnist-translator** działa w dwóch trybach: trenowania offline i wnioskowania (offline z CSV lub na żywo z kamery). Oba tryby korzystają z identycznego potoku ekstrakcji cech, co gwarantuje spójność przestrzeni cech. Schemat architektury systemu wykorzystany w projekcie znajduje się w katalogu `diagrams` i został przedstawiony na rysunku 2.2.



Rys. 2.1. Schemat systemu mnist-translator

2.1.2. Potok przetwarzania danych

Dane przepływają przez następujące moduły:

1. **Ingestion** (`src/data/ingest.py`) — wczytanie pliku CSV do struktury `DataFrame` i normalizacja pikseli do `[0, 1]`.
2. **Ekstrakcja cech** (`src/data/extract.py`) — budowa macierzy cech `X` (784 kolumny) i wektora etykiet `y`.
3. **Podział danych** (`src/data/split.py`) — stratyfikowany podział 80/10/10 na zbiory treninowy, walidacyjny i testowy.

4. **Trenowanie** (`src/model/train.py`) — dopasowanie wybranego klasyfikatora i zapis artefaktu do katalogu `artifacts/`.
5. **Ewaluacja** (`src/model/evaluate.py`) — wyznaczenie dokładności globalnej i raportu per-klasa.
6. **Inferencja** (`src/inference/`) — wczytanie modelu i klasyfikacja nowego wektora cech.

2.1.3. Warunki pomiarowe przy inferowaniu z kamery

Jakość predykcji w trybie kamerowym jest wrażliwa na warunki otoczenia. Tabela 2.1 zestawia zalecane ustawienia.

Tabela 2.1. Zalecane warunki podczas inferencji z kamery

Parametr	Zalecana wartość
Oświetlenie	Równomierne, bez twardych cieni na dłoni
Dłoń	Lewa, skierowana przodem do kamery
Kamera	DroidCam lub dowolna obsługiwana przez OpenCV
Tryb lustra	Wyłączony w aplikacji kamery
Tło	Jednolity, kontrastowy kolor

2.2. Opis implementacji

2.2.1. Struktura projektu

Listing 2.1. Struktura katalogów projektu `mnist-translator`

```
mnist-translator/
|-- main.py                # Punkt wejścia CLI (brak logiki biznesowej)
|-- pyproject.toml         # Zarządzanie zależnościami (uv)
|-- src/
|   |-- data/
|   |   |-- ingest.py      # Ładowanie CSV i normalizacja pikseli
|   |   |-- extract.py     # Budowa macierzy cech X i etykiet y
|   |   |-- split.py       # Stratyfikowany podział 80/10/10
|   |   |-- protocol.py    # Protokół DataSource
|   |-- model/
|   |   |-- train.py       # Trenowanie + zapis artefaktu
|   |   |-- evaluate.py    # Obliczanie metryk dokładności
|   |   |-- classifiers/
|   |   |   |-- svc.py     # Klasyfikator SVC z jądrem RBF
|   |   |   |-- random_forest.py # Las Losowy (200 drzew)
|   |   |   |-- cnn.py     # Konwolucyjna sieć neuronowa
|   |-- inference/
|   |   |-- camera.py      # Przechwytywanie wideo + MediaPipe
|   |   |-- csv_source.py  # Źródło cech z wiersza CSV
|   |   |-- predict.py     # Ładowanie modelu i predykcja
|   |   |-- protocol.py    # Protokół FeatureSource
|-- tests/                 # Testy jednostkowe (pytest)
|-- diagrams/              # Diagram architektury
|-- artifacts/             # Wytrenowane modele (gitignored)
```

2.2.2. Interfejs wiersza poleceń

Plik `main.py` udostępnia trzy tryby działania:

Tabela 2.2. Tryby działania aplikacji `mnist-translator`

Tryb	Opis	Kluczowe opcje
<code>train</code>	Trenuje klasyfikator i zapisuje artefakt	<code>--classifier {svc, rf, cnn}</code> , <code>--model</code> , <code>--dataset</code>
<code>eval</code>	Ewaluuje model na zbiorze testowym	<code>--model</code> , <code>--dataset</code>
<code>infer</code>	Inferencja z CSV lub z kamery	<code>--source {csv, camera}</code> , <code>--row</code> , <code>--camera</code>

2.2.3. Implementacja klasyfikatorów

2.2.3.1. SVC z jądrem RBF

Listing 2.2. Budowa potoku SVC (`src/model/classifiers/svc.py`)

```

1 from sklearn.svm import SVC
2 from sklearn.pipeline import Pipeline
3 from sklearn.preprocessing import StandardScaler
4
5 def build_svc() -> Pipeline:
6     """Buduje potok: standaryzacja + SVC z jądrem RBF."""
7     return Pipeline([
8         ("scaler", StandardScaler()),
9         ("svc", SVC(kernel="rbf", C=10, gamma="scale",
10             decision_function_shape="ovr")),
11     ])

```

2.2.3.2. Las Losowy

Listing 2.3. Budowa Lasu Losowego (`src/model/classifiers/random_forest.py`)

```

1 from sklearn.ensemble import RandomForestClassifier
2
3 def build_random_forest() -> RandomForestClassifier:
4     """200 drzew, tryb OOB włączony."""
5     return RandomForestClassifier(
6         n_estimators=200,
7         random_state=42,
8         oob_score=True,
9         n_jobs=-1,
10    )

```

2.2.3.3. Konwolucyjna sieć neuronowa

Listing 2.4. Architektura CNN (`src/model/classifiers/cnn.py`)

```

1 import tensorflow as tf
2
3 def build_cnn(num_classes: int = 24) -> tf.keras.Model:

```

```

4     """Dwa bloki Conv2D->MaxPool + warstwa wyjsciowa z softmax."""
5     model = tf.keras.Sequential([
6         tf.keras.layers.Input(shape=(28, 28, 1)),
7         tf.keras.layers.Conv2D(32, (3, 3), activation="relu",
8             padding="same"),
9         tf.keras.layers.MaxPooling2D(),
10        tf.keras.layers.Conv2D(64, (3, 3), activation="relu",
11            padding="same"),
12        tf.keras.layers.MaxPooling2D(),
13        tf.keras.layers.Flatten(),
14        tf.keras.layers.Dense(128, activation="relu"),
15        tf.keras.layers.Dropout(0.3),
16        tf.keras.layers.Dense(num_classes, activation="softmax"),
17    ])
18    model.compile(optimizer="adam",
19        loss="sparse_categorical_crossentropy",
20        metrics=["accuracy"])
21    return model

```

2.2.4. Serializacja modeli

Modele scikit-learn są zapisywane i wczytywane za pomocą biblioteki `joblib`:

Listing 2.5. Zapis i odczyt modelu scikit-learn

```

1 import joblib
2
3 # Zapis modelu
4 joblib.dump(model, "artifacts/svc_model.pkl")
5
6 # Wczytanie modelu
7 model = joblib.load("artifacts/svc_model.pkl")

```

Model CNN jest zapisywany w formacie natywnym Keras (rozszerzenie `.keras`):

Listing 2.6. Zapis i odczyt modelu CNN (Keras)

```

1 # Zapis
2 model.save("artifacts/cnn_model.keras")
3
4 # Wczytanie
5 import tensorflow as tf
6 model = tf.keras.models.load_model("artifacts/cnn_model.keras")

```

2.2.5. Główne zależności

Tabela 2.3. Główne zależności projektu (pyproject.toml)

Biblioteka	Zastosowanie
numpy, pandas	Manipulacja danymi i macierzami
scikit-learn	SVC, Random Forest, metryki
joblib	Serializacja modeli
opencv-python	Przechwytywanie klatek z kamery
mediapipe	Detekcja dłoni i punktów kluczowych
tensorflow >= 2.21.0	Budowa i trenowanie CNN

3. Eksperymenty i wyniki

3.1. Opis eksperymentów

3.1.1. Cel eksperymentów

Eksperymenty miały na celu porównanie trzech metod klasyfikacji pod względem dokładności na tych samych danych testowych oraz jakości predykcji w warunkach rzeczywistych (inferencja z kamery).

3.1.2. Podział danych

Dane treningowe z pliku `sign_mnist_train.csv` zostały podzielone stratyfikowanie na podzbiory:

- **Treningowy (80%)** — używany do dopasowania parametrów modelu.
- **Walidacyjny (10%)** — opcjonalnie do strojenia hiperparametrów.
- **Testowy (10%)** — do pomiaru końcowej dokładności.

Plik `sign_mnist_test.csv` (7 172 próbki) pełnił rolę niezależnego zbioru testowego wymaganego przez dokumentację projektu.

3.1.3. Procedura trenowania i ewaluacji

Dla każdego klasyfikatora procedura była identyczna:

1. Wczytanie `sign_mnist_train.csv` i normalizacja pikseli.
2. Stratyfikowany podział 80/10/10.
3. Trenowanie modelu na zbiorze treningowym.
4. Zapis artefaktu do katalogu `artifacts/`.
5. Ewaluacja na niezależnym zbiorze testowym.

3.1.3.1. Trenowanie SVC

Listing 3.1. Polecenie trenowania klasyfikatora SVC

```
1 uv run python main.py train \  
2   --classifier svc \  
3   --model artifacts/svc_model.pkl \  
4   --dataset data/raw/sign_mnist_train.csv
```

3.1.3.2. Trenowanie Lasu Losowego

Listing 3.2. Polecenie trenowania Lasu Losowego

```
1 uv run python main.py train \  
2   --classifier rf \  
3   --model artifacts/rf_model.pkl \  
4   --dataset data/raw/sign_mnist_train.csv
```

3.1.3.3. Trenowanie CNN

Listing 3.3. Polecenie trenowania CNN

```
1 uv run python main.py train \
2   --classifier cnn \
3   --model artifacts/cnn_model.keras \
4   --dataset data/raw/sign_mnist_train.csv
```

3.1.3.4. Ewaluacja modeli

Listing 3.4. Ewaluacja modelu SVC na zbiorze testowym

```
1 uv run python main.py eval \
2   --model artifacts/svc_model.pkl \
3   --dataset data/raw/sign_mnist_test.csv
```

Wynikiem jest dokładność globalna oraz raport `classification_report` ze scikit-learn zawierający precyzję, czułość i miarę F1 dla każdej klasy.

3.1.4. Test w warunkach rzeczywistych

Po wytrenowaniu modeli przeprowadzono testy jakościowe z użyciem kamery internetowej, zachowując warunki zestawione w tabeli 2.1. Każdą z 24 liter testowano przez minimum 5 sekund, obserwując stabilność predykcji w oknie OpenCV.

Listing 3.5. Uruchomienie inferencji z kamery

```
1 uv run python main.py infer \
2   --source camera \
3   --camera 0 \
4   --model artifacts/svc_model.pkl
```

3.2. Wyniki

3.2.1. Dokładność na zbiorze testowym

Tabela 3.1. Porównanie dokładności klasyfikatorów na zbiorze testowym Sign Language MNIST

Model	Plik artefaktu	Dok. testowa
SVC (jądro RBF)	<code>artifacts/svc_model.pkl</code>	0,82
Las Losowy (200 drzew)	<code>artifacts/rf_model.pkl</code>	0,82
CNN (Keras/TF)	<code>artifacts/cnn_model.keras</code>	0,92

CNN osiąga wyraźnie wyższą dokładność (92%) w porównaniu z SVC i RF (oba 82%). Wynik jest spójny z literaturą — architektury konwolucyjne są naturalnie przystosowane do danych obrazowych.

3.2.2. Obserwacje jakościowe z inferencji kamerowej

- **SVC** — predykcja stabilna w dobrym oświetleniu, wrażliwa na obrót dłoni i niejednolite tło.

- **Las Losowy** — podobna stabilność jak SVC; tendencja do nadmiernej pewności siebie przy niskiej jakości obrazu.
- **CNN** — najbardziej odporna predykcja; lepiej radzi sobie z lekkimi zmianami pozycji dłoni i oświetlenia.

We wszystkich modelach litery wizualnie podobne (np. M/N, R/U) powodowały częstsze błędy klasyfikacji.

3.3. Dyskusja wyników

3.3.1. Przewaga CNN nad metodami klasycznymi

Różnica 10 punktów procentowych na korzyść CNN wynika z fundamentalnej cechy architektury: warstwy konwolucyjne uczą się hierarchicznych reprezentacji przestrzennych — krawędzi, narożników i wzorców wyższego rzędu — których płaski wektor 784 cech nie przekazuje. SVC i RF operują na przestrzeni 784-wymiarowej bez żadnego uwzględnienia sąsiedztwa pikseli.

3.3.2. Równoważność SVC i Lasu Losowego

Zbliżona dokładność obu metod (82%) sugeruje, że granica decyzyjna jest podobnie złożona: wystarczająco skomplikowana, by wymagać nieliniowych metod, ale niewystarczająco złożona, by jedna metoda miała wyraźną przewagę bez dalszego strojenia hiperparametrów.

3.3.3. Ograniczenia podejścia pikselowego

Operowanie na surowych pikselach po normalizacji wiąże się z istotnymi ograniczeniami praktycznymi:

- **Wrażliwość na oświetlenie** — zmiana natężenia lub kierunku światła modyfikuje wartości pikseli i może prowadzić do błędnych predykcji.
- **Wrażliwość na pozycję** — dłoń musi być wycentrowana w kadrze i podobnej skali co próbki treningowe.
- **Brak niezmienności geometrycznej** — modele nie są z natury niezmiennicze na obrót, skalę ani przesunięcie; CNN częściowo kompensuje to przez operację *max pooling*.

3.3.4. Rola MediaPipe w systemie

Kluczową rolą MediaPipe jest dostarczenie bounding boxa dłoni, dzięki czemu przycięty i przeskalowany fragment klatki jest znacznie bardziej zbliżony do próbek treningowych niż surowy obraz z kamery. Bez tego kroku predykcje byłyby praktycznie bezużyteczne. Jednocześnie MediaPipe bywa zawodny przy słabym oświetleniu lub gdy dłoń nie jest wyraźnie wyeksponowana.

3.3.5. Kierunki ulepszeń

1. Zastąpienie pikseli punktami kluczowymi MediaPipe (21 wartości xyz) jako cechami wejściowymi — reprezentacja bardziej abstrakcyjna i mniej wrażliwa na oświetlenie.
2. Augmentacja danych (obroty, skalowanie, szum gaussowski) podczas trenowania CNN.
3. Transfer learning na modelach wstępnie wytrenowanych (np. MobileNetV3).
4. Strojenie hiperparametrów SVC (parametry C i γ) za pomocą przeszukiwania siatki (*GridSearchCV*).

4. Wnioski i dodatek

4.1. Wnioski

1. **CNN przewyższa metody klasyczne** na zadaniu klasyfikacji znaków ASL: osiąga 92% dokładności wobec 82% dla SVC i Lasu Losowego. Architektura konwolucyjna jest naturalnie dostosowana do danych obrazowych.
2. **SVC i Las Losowy osiągają identyczną dokładność (82%)** pomimo różnych strategii uczenia, co sugeruje, że obie metody osiągnęły podobną granicę dla tej reprezentacji danych.
3. **Jakość inferencji kamerowej zależy od warunków zewnętrznych** — oświetlenia, tła i pozycji dłoni — bardziej niż od wyboru klasyfikatora.
4. **MediaPipe odgrywa kluczową rolę** w przygotowaniu wejścia modelu; bez etapu detekcji dłoni system nie nadaje się do praktycznego zastosowania.
5. **Podejście pikselowe ma istotne ograniczenia praktyczne**. Reprezentacja oparta na punktach kluczowych mogłaby znacząco poprawić odporność systemu na zmienne warunki otoczenia.
6. **Modularna architektura projektu** (rozdzielenie warstw danych, modeli i inferencji) ułatwia wymianę komponentów i jest dobrą praktyką inżynierską w projektach uczenia maszynowego.

Dodatek: Instrukcja samodzielnej realizacji ćwiczenia

Poniższy przewodnik umożliwia samodzielne przeprowadzenie ćwiczenia od konfiguracji środowiska po uruchomienie inferencji na żywo.

Krok 1: Pobranie repozytorium

Listing 4.1. Klonowanie repozytorium

```
git clone https://github.com/JustFiesta/mnist-translator.git
cd mnist-translator
```

Krok 2: Instalacja środowiska Python

Listing 4.2. Konfiguracja środowiska wirtualnego

```
# Instalacja Pythona 3.13 przez menedżera uv
uv python install 3.13
uv venv --python 3.13

# Windows PowerShell
.venv\Scripts\Activate.ps1

# Linux / macOS
source .venv/bin/activate

# Instalacja zależności z pliku lock
uv sync
```

Krok 3: Pobranie zbioru danych

1. Przejdź na stronę Kaggle:
<https://www.kaggle.com/datasets/datamunge/sign-language-mnist/data>
2. Pobierz pliki `sign_mnist_train.csv` i `sign_mnist_test.csv`.
3. Utwórz katalog docelowy i umieść w nim pobrane pliki:

Listing 4.3. Przygotowanie struktury katalogów na dane

```
# Windows PowerShell
New-Item -ItemType Directory -Path data/raw -Force

# Linux / macOS
mkdir -p data/raw

# Skopiuj pobrane pliki CSV do katalogu data/raw/
```

Krok 4: Trenowanie modeli

Listing 4.4. Trenowanie wszystkich trzech klasyfikatorów

```
# SVC (domyslny, najszybszy)
uv run python main.py train

# Las Losowy
uv run python main.py train --classifier rf --model artifacts/rf_model.pkl

# CNN (trenowanie moze zajac kilka minut)
uv run python main.py train --classifier cnn --model artifacts/cnn_model.keras
```

Krok 5: Ewaluacja modeli

Listing 4.5. Ewaluacja wytrenowanych modeli

```
# Ewaluacja SVC
uv run python main.py eval \
    --model artifacts/svc_model.pkl \
    --dataset data/raw/sign_mnist_test.csv

# Ewaluacja Lasu Losowego
uv run python main.py eval \
    --model artifacts/rf_model.pkl \
    --dataset data/raw/sign_mnist_test.csv

# Ewaluacja CNN
uv run python main.py eval \
    --model artifacts/cnn_model.keras \
    --dataset data/raw/sign_mnist_test.csv
```

Zanotuj dokładność każdego modelu i porównaj z wynikami z tabeli 3.1.

Krok 6: Inferencja offline (z pliku CSV)

Listing 4.6. Inferencja na wybranym wierszu pliku CSV

```
uv run python main.py infer \
  --source csv \
  --row 42 \
  --dataset data/raw/sign_mnist_test.csv \
  --model artifacts/svc_model.pkl
```

Krok 7: Inferencja na żywo z kamery

Listing 4.7. Uruchomienie inferencji w czasie rzeczywistym

```
uv run python main.py infer \
  --source camera \
  --camera 0 \
  --model artifacts/svc_model.pkl
```

Uwagi:

- Przy pierwszym uruchomieniu aplikacja automatycznie pobierze plik modelu MediaPipe (`gesture_recognizer.task`) — wymagany jest dostęp do Internetu.
- Naciśnij klawisz `q`, aby zakończyć działanie okna kamery.
- Jeśli kamera nie jest wykrywana pod indeksem 0, spróbuj opcji `--camera 1`.

Krok 8: Uruchomienie testów jednostkowych

Listing 4.8. Uruchamianie testów pytest

```
# Wszystkie testy
uv run pytest

# Testy z raportem pokrycia kodu
uv run pytest --cov=src --cov-report=term-missing
```

Pytania kontrolne

1. Dlaczego litery J i Z nie są uwzględnione w zbiorze Sign Language MNIST?
2. Jaką rolę pełni MediaPipe w potoku inferencji kamerowej?
3. Co oznacza stratyfikowany podział danych i dlaczego jest ważny przy niezbalansowanych klasach?
4. Jaka jest różnica między parametrami C i γ w SVC z jądrem RBF?
5. Dlaczego CNN osiąga wyższą dokładność niż SVC na danych obrazowych?
6. W jaki sposób można poprawić odporność systemu na zmienne oświetlenie?

5. Implementacja systemu

5.1. Architektura logiczna

Projekt został podzielony na trzy warstwy:

- `src/data` – przygotowanie danych i podziału zbioru,
- `src/model` – uczenie i ewaluacja klasyfikatorów,
- `src/inference` – predykcja offline i online (kamera).

Warstwa wejściowa CLI znajduje się w `main.py` i deleguje logikę do modułów w `src/`. Takie podejście upraszcza testowanie i ogranicza sprzężenie między interfejsem użytkownika a logiką przetwarzania.

5.2. Przetwarzanie danych

Klasa `CsvDataset` ładuje plik CSV i wymusza spójność schematu (obecność kolumny `label` oraz dokładnie 784 cechy obrazu). Dla każdej próbki zwracana jest para:

```
(feature_vector: np.ndarray, label: str)
```

Wektor cech jest typu `float32` i przyjmuje wartości w $[0, 1]$. Etykiety numeryczne przekształcane są do liter poprzez mapowanie:

$$y_{letter} = \text{chr}(\text{ord}('A') + y_{int}) \quad (5.1)$$

Budowa macierzy cech realizowana jest przez `build_feature_matrix`, a podział danych przez `stratified_split`. Domyślnie stosowany jest podział 80/10/10 z zachowaniem proporcji klas.

5.3. Uczenie modeli

Moduł `src/model/train.py` obsługuje trzy warianty klasyfikatorów:

- **SVC (RBF)** – domyślny klasyfikator oparty o jądro radialne,
- **Random Forest** – las losowy o 200 drzewach,
- **CNN (Keras)** – sieć konwolucyjna dla wejścia 28×28 .

Modele klasyczne serializowane są przez `joblib` do formatu `.pkl`. Model konwolucyjny zapisywany jest jako `.keras` oraz osobny plik mapowania etykiet `.labels.json`.

5.4. Ewaluacja jakości

Funkcja `evaluate` oblicza dokładność globalną oraz raport klasyfikacji `classification_report` biblioteki `scikit-learn` [8]. Wyniki zwracane są również jako słownik, co upraszcza dalsze automatyczne raportowanie.

5.5. Inferencja: CSV i kamera

Inferencja offline z jednego wiersza CSV realizowana jest przez `CsvRowSource`. Inferencja online wykorzystuje klasę `CameraSource`, która:

1. pobiera klatkę z kamery (OpenCV [7]),
2. wykrywa dłoń przez MediaPipe GestureRecognizer [3],
3. wyznacza obszar dłoni i dokonuje kadrowania,
4. przeskalowuje obraz do 28×28 oraz normalizuje piksele,
5. przekazuje wektor 784 cech do modelu.

W przypadku braku detekcji dłoni moduł zwraca wektor zerowy, dzięki czemu interfejs inferencji pozostaje stabilny.

5.6. Interfejs CLI

Plik `main.py` udostępnia trzy tryby:

- `train` – trening wybranego klasyfikatora,
- `eval` – ewaluacja zapisanego modelu,
- `infer` – predykcja z CSV lub kamery.

Przykładowe użycie:

Listing 5.1. Przykłady uruchomien CLI

```
1 uv run python main.py train --classifier svc --model artifacts/svc_model.pkl
2 uv run python main.py eval --model artifacts/svc_model.pkl --dataset data/raw/
  sign_mnist_test.csv
3 uv run python main.py infer --source csv --row 42 --dataset data/raw/sign_mnist_test.csv
4 uv run python main.py infer --source camera --camera 0 --model artifacts/svc_model.pkl
```

6. Wyniki i analiza

6.1. Założenia środowiska testowego

Podczas weryfikacji inferencji kamerowej przyjęto następujące warunki:

- równomierne oświetlenie bez silnych cieni,
- jednolite tło ograniczające fałszywe detekcje,
- dłoń ustawiona frontalnie względem kamery,
- wyłączone odbicie lustrzane obrazu.

Zmiana warunków oświetlenia lub geometrii kadru obniża jakość detekcji dłoni, a tym samym stabilność predykcji.

6.2. Wyniki porównawcze modeli

Na podstawie danych projektu uzyskano następujące wyniki dokładności:


Tabela 6.1. Porównanie modeli klasyfikacyjnych

Model	Artefakt	Dokładność testowa
SVC (RBF)	artifacts/svc_model.pkl	0,82
Random Forest	artifacts/rf_model.pkl	0,82
CNN (Keras / TF)	artifacts/cnn_model.keras	0,92

Wyniki wskazują przewagę modelu CNN, co jest zgodne z charakterem danych obrazowych, dla których lokalne cechy przestrzenne mają istotne znaczenie.

6.3. Schemat przepływu systemu

Architekturę wysokiego poziomu projektu przedstawiono na rysunku 6.1.



Rys. 6.1. Architektura rozwiązania: dane, trening i inferencja

6.4. Analiza jakości inferencji w czasie rzeczywistym

W trybie `infer -source camera` system wykonuje predykcję dla każdej klatki wejściowej. Jakość predykcji zależy od:

1. poprawnej detekcji konturu dłoni przez MediaPipe,
2. jakości kadrowania i skalowania do 28×28 ,
3. zgodności rozkładu danych wejściowych z rozkładem treningowym.

Najczęstsze problemy obserwowane podczas demonstracji:

- brak dostępu do kamery (`camera_index` zajęty),
- słaba separacja dłoni od tła,
- częściowe wyjście dłoni poza obszar kadru.

6.5. Ograniczenia obecnej wersji

Wersja aktualna jest rozwiązaniem klasyfikacji pojedynczych klatek i nie modeluje dynamiki ruchu. Oznacza to, że:

- znaki wymagające ruchu (np. J, Z) nie są klasyfikowane,
- brak jest mechanizmu wygładzania predykcji po czasie,
- brak detekcji kontekstu sekwencji gestów.

Mimo tych ograniczeń projekt spełnia cel dydaktyczny i demonstracyjny: spójny pipeline od danych tablicowych do inferencji online.

7. Wnioski

7.1. Podsumowanie realizacji

W ramach projektu zrealizowano kompletny pipeline klasyfikacji znaków dłoni: od przygotowania danych tablicowych, przez uczenie i ewaluację modeli, po inferencję z kamery w czasie rzeczywistym. Implementacja zachowuje spójny format wejścia (28×28 , 784 cechy), co pozwala stosować różne klasyfikatory bez zmian interfejsu danych.

7.2. Ocena zastosowanych metod

Przeprowadzone porównanie pokazuje, że:

- modele klasyczne (SVC, RandomForest) zapewniają zadowalającą bazową skuteczność,
- model konwolucyjny (CNN) uzyskuje wyraźnie wyższą dokładność,
- jakość inferencji online zależy nie tylko od modelu, ale także od jakości detekcji i preprocesingu obrazu.

7.3. Ograniczenia i ryzyka

Najważniejsze ograniczenia obecnej wersji:

1. klasyfikacja oparta na pojedynczych klatkach bez modelowania sekwencji,
2. brak obsługi znaków dynamicznych wymagających ruchu,
3. podatność na zmiany oświetlenia i tła,
4. brak kalibracji pod indywidualne różnice użytkowników.

7.4. Kierunki dalszego rozwoju

Rozszerzenia, które mogą poprawić jakość i użyteczność systemu:

- dodanie modelu sekwencyjnego (np. LSTM/Transformer) dla rozpoznawania gestów dynamicznych,
- wygładzanie predykcji w oknie czasowym,
- augmentacja danych i rozszerzenie zbioru treningowego o rzeczywiste próbki z kamery,
- budowa modułu oceny wydajności czasu inferencji na różnych urządzeniach.

7.5. Wniosek końcowy

Projekt spełnia cele laboratorium z zakresu sztucznej inteligencji: łączy techniki uczenia maszynowego i przetwarzania obrazu w działającym prototypie klasyfikatora znaków dłoni, który może stanowić bazę do dalszych prac badawczych i inżynierskich.

Bibliografia

- [1] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [2] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995.
- [3] Google MediaPipe. Mediapipe solutions and tasks, 2026. Dostęp: 2026-06-13.
- [4] Yann LeCun, Bernhard Boser, John S. Denker, Donnie Henderson, Richard E. Howard, Wayne Hubbard, and Lawrence D. Jackel. Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1(4):541–551, 1989.
- [5] Yann LeCun, Leon Bottou, Yoshua Bengio, and Patrick Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [6] Camillo Lugaresi et al. Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- [7] OpenCV Team. Opencv documentation, 2026. Dostęp: 2026-06-13.
- [8] scikit-learn developers. scikit-learn documentation, 2026. Dostęp: 2026-06-13.

Spis rysunków

2.1	Schemat systemu mnist-translator	9
2.2	Schemat systemu mnist-translator	10
6.1	Architektura rozwiązania: dane, trening i inferencja	23

Spis tabel

1.1	Statystyki zbioru danych Sign Language MNIST	7
2.1	Zalecane warunki podczas inferencji z kamery	11
2.2	Tryby działania aplikacji mnist-translator	12
2.3	Główne zależności projektu (pyproject.toml)	13
3.1	Porównanie dokładności klasyfikatorów na zbiorze testowym Sign Language MNIST . . .	15
6.1	Porównanie modeli klasyfikacyjnych	22

Spis listingów

2.1	Struktura katalogów projektu mnist-translator	11
2.2	Budowa potoku SVC (src/model/classifiers/svc.py)	12
2.3	Budowa Lasu Losowego (src/model/classifiers/random_forest.py)	12
2.4	Architektura CNN (src/model/classifiers/cnn.py)	12
2.5	Zapis i odczyt modelu scikit-learn	13
2.6	Zapis i odczyt modelu CNN (Keras)	13
3.1	Polecenie trenowania klasyfikatora SVC	14
3.2	Polecenie trenowania Lasu Losowego	14
3.3	Polecenie trenowania CNN	15
3.4	Ewaluacja modelu SVC na zbiorze testowym	15
3.5	Uruchomienie inferencji z kamery	15
4.1	Klonowanie repozytorium	17
4.2	Konfiguracja środowiska wirtualnego	17
4.3	Przygotowanie struktury katalogów na dane	18
4.4	Trenowanie wszystkich trzech klasyfikatorów	18
4.5	Ewaluacja wytrenowanych modeli	18
4.6	Inferencja na wybranym wierszu pliku CSV	19
4.7	Uruchomienie inferencji w czasie rzeczywistym	19
4.8	Uruchamianie testów pytest	19
5.1	Przykłady uruchomien CLI	21